

Курсовая работа: Анализ рисков юридических лиц

Якубовская Анастасия

2026-09-04

Содержание

0.1	Общее описание данных	1
0.2	Проведем первичный анализ данных	1
0.3	Вопрос 1: Связано ли общее количество записей компании в телефонных книгах с долей плохих оценок? Проявляется ли связь сильнее у руководителей?	5
0.4	Вопрос 2: Связана ли высокая доля претензий по кредитам с общей долей негатив в ТК?	7
0.5	Вопрос 3: Правда ли что компании с юльшим количеством отзывов на платформах обладают меньшей долей негатива в телефонных книгах?	8
0.6	Вопрос 4: Как изменяется количество негативных отзывов в зависимости от активности?	10
0.7	Вопрос 5: Попытка предсказать негативный рейтинг	12

0.1. Общее описание данных

15000 юридических лиц, со следующими характеристиками: - id компании, дата скоринга компании - данные телефонных книг - кредитные заявки и претензии - судебная практика и запросы МВД - внешние рейтинги

0.2. Проведем первичный анализ данных

Вначале узнаем общий объем информации, количество признаков и типы всех переменных

```
cat(dim(df)[1], dim(df)[2]) # 15000 записей и 35 колонок
```

```
## 15000 35
```

```
str(df) # видим пропуски в полях bad_rep_tcb, claims_percent, их требуется обработать
```

```
## 'data.frame':    15000 obs. of  35 variables:
## $ id              : chr  "a782615660478a" "a7706752171a" "a745212602258a" "a2466264323a"
## $ date            : chr  "2022-10-30 00:00:00" "2022-01-15 00:00:00" "2021-06-03 00:00:00" "2022-09-25 00:00:00" ...
## $ phones_num      : int   1 16 4 3 161 8 3 5 5 13 ...
## $ phb_fraud       : num   0 0 0 0 4 1 76 0 0 0 ...
## $ phb_dirty       : num   2 0 0 0 2 0 0 0 0 0 ...
## $ phb_all_bad     : num   2 0 0 0 6 1 76 0 0 0 ...
## $ phb_all         : num  1498 2421 1503 77 17842 ...
## $ phb_bad_perc    : num   0.13 0 0 0 0.03 ...
## $ found_phones    : num   1 16 3 2 145 6 3 2 5 12 ...
## $ phb_fraud_dir   : num   0 0 0 0 0 0 10 0 0 0 ...
## $ phb_dirty_dir   : num   0 0 0 3 0 0 0 0 0 0 ...
## $ phb_all_bad_dir : num   0 0 0 3 0 0 10 0 0 0 ...
## $ phb_all_dir     : num  410 121 159 742 695 311 644 1 434 115 ...
## $ phb_bad_perc_dir : num   0 0 0 0.4 0 0 1.55 0 0 0 ...
## $ found_phones_dir : num   2 1 1 2 1 2 2 1 3 2 ...
```

```
## $ claims_percent      : num  0 NA 0 0 0 NA NA NA NA NA ...
## $ claims_num          : num  0 NA 0 0 0 NA NA NA NA NA ...
## $ appl_num            : num  8 NA 2 1 1 NA NA NA NA NA ...
## $ complaints_num      : num  NA NA NA NA NA NA NA NA NA NA ...
## $ complaints_num_dir  : num  NA NA NA NA NA NA NA NA NA NA ...
## $ mvd_request_num     : num  1 NA NA NA NA NA NA NA NA NA ...
## $ bad_rep_tcb         : num  NA NA NA NA NA NA NA NA NA NA ...
## $ total_case_cnt      : num  NA NA NA NA NA NA NA NA NA NA ...
## $ total_defendant_case_cnt: num  NA NA NA NA NA NA NA NA NA NA ...
## $ total_defendant_case_amt: num  NA NA NA NA NA NA NA NA NA NA ...
## $ defendant_case_perc : num  NA NA NA NA NA NA NA NA NA NA ...
## $ rating_ya           : num  NA 4.15 NA NA 4.15 4.9 4.9 NA NA 4.3 ...
## $ ratings_cnt_ya      : num  0 114 0 0 21338 ...
## $ reviews_cnt_ya     : num  15 39 4 2 5772 ...
## $ rating_yell         : num  4 3.7 4 4.5 4.24 ...
## $ reviews_cnt_yell   : num  0 1 0 0 308 0 0 0 0 0 ...
## $ rating_2gis         : num  0 0.143 0 4.8 1.358 ...
## $ reviews_cnt_2gis   : num  0 2 0 5 2943 ...
## $ rating_avito        : num  NA 4.8 NA NA NA NA NA NA 5 NA ...
## $ reviews_cnt_avito  : num  NA 5 NA NA NA NA NA NA 2 NA ...
```

Обработаем пропуски, которые есть в данных. Выясним в каких данных есть пропуски и узнаем их процент, построим график

```
missing_info <- df %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(cols = everything(), names_to = "variable", values_to = "na_count") %>%
  mutate(na_perc = round((na_count / nrow(df)) * 100, 2)) %>%
  filter(na_count > 0) %>%
  arrange(desc(na_perc))
# Построим таблицу пропусков
knitr::kable(missing_info, col.names = c("Переменная", "Кол-во", "Процент"),
  caption = "Таблица переменных с пропущенными значениями")
```

Таблица 1: Таблица переменных с пропущенными значениями

Переменная	Кол-во	Процент
complaints_num	14982	99.88
complaints_num_dir	14954	99.69
total_case_cnt	14936	99.57
total_defendant_case_cnt	14936	99.57
total_defendant_case_amt	14936	99.57
defendant_case_perc	14936	99.57
bad_rep_tcb	14873	99.15
rating_avito	14686	97.91
reviews_cnt_avito	14577	97.18
mvd_request_num	13998	93.32
rating_ya	11604	77.36
ratings_cnt_ya	10523	70.15
reviews_cnt_ya	10523	70.15
rating_yell	9413	62.75
reviews_cnt_yell	9413	62.75
rating_2gis	8318	55.45
reviews_cnt_2gis	8318	55.45

Переменная	Кол-во	Процент
claims_percent	5102	34.01
claims_num	5102	34.01
appl_num	5102	34.01
phb_fraud_dir	1231	8.21
phb_dirty_dir	1231	8.21
phb_all_bad_dir	1231	8.21
phb_all_dir	1231	8.21
phb_bad_perc_dir	1231	8.21
found_phones_dir	1231	8.21
phb_fraud	11	0.07
phb_dirty	11	0.07
phb_all_bad	11	0.07
phb_all	11	0.07
phb_bad_perc	11	0.07
found_phones	11	0.07

Пропуски находятся на мой взгляд в достаточно логичных местах и их можно интерпретировать: основная часть пропусков находится в судебных делах и жалобах, что может означать, что у команды просто не было жалоб и они не участвовали в судебных делах. Пропуск во внешних рейтингах означает, что у компании просто нет карточки на сайте компании ## Далее посмотрим на распределение целевой переменной (флаг репутации)


```
target_summary <- df %>%
  group_by(bad_rep_tcb) %>%
  summarise(
    Count = n(),
    Percentage = round(n() / nrow(df) * 100, 2)
  )

knitr::kable(target_summary, col.names = c("bad_rep_tcb", "Количество", "Доля"),
  caption = "Распределение компаний по флагу репутации")
```

Таблица 2: Распределение компаний по флагу репутации

bad_rep_tcb	Количество	Доля
0	103	0.69
1	24	0.16
NA	14873	99.15

```
ggplot(df, aes(x = factor(bad_rep_tcb, labels = c("Хорошая репутация", "Плохая репутация")),
  fill = factor(bad_rep_tcb))) +
  geom_bar(alpha = 0.85, show.legend = FALSE) +
  scale_fill_manual(values = c("0" = "#2c7fb8", "1" = "#de2d26")) +
  geom_text(stat = 'count', aes(label = ..count..), vjust = -0.5, fontface = "bold") +
  labs(
    title = "Соотношение компаний с хорошей и плохой репутацией",
    x = "Категория",
    y = "Количество"
  ) +
  theme_minimal()
```



Можно увидеть достаточно сильный дисбаланс флаг есть только у 24 компаний, а подтвержденная хорошая репутация стоит у 103 компаний, в то время как у остальных 14873 компаний стоит пропуск. Это означает, что в исследовании по больше части следует опираться на другие данные

Чтобы сгладить сильную ассиметрию и для корректного анализа логарифмируем показатели

```
library(gridExtra)
```

```
df <- df %>%
```

```
  mutate (
```

```
    log_phb_all = log1p(phb_all),
```

```
    log_phb_all_bad = log1p(phb_all_bad),
```

```
    log_phb_all_bad_dir = log1p(phb_all_bad_dir),
```

```
    log_defendant_amt = log1p(ifelse(is.na(total_defendant_case_amt), 0, total_defendant_cas
```

```
  )
```

```
p1 <- ggplot(df, aes(x = phb_all_bad)) +
```

```
  geom_histogram(bins = 30, fill = "#e6550d", alpha = 0.7) +
```

```
  labs(title = "Негативные записи в ТК", x = "phb_all_bad", y = "Количество") +
```

```
  theme_minimal()
```


```
p2 <- ggplot(df, aes(x = log_phb_all_bad)) +
```

```
  geom_histogram(bins = 30, fill = "#31a354", alpha = 0.7) +
```

```
  labs(title = "Негативные записи в ТК (log1p)", x = "log(1 + phb_all_bad)", y = "Количество")
```

```
  theme_minimal()
```

```
grid.arrange(p1, p2, ncol = 2)
```




Начнем формулировку вопросов, поскольку целевая переменная не сильно информативная, проверим блок данных, где почти нет пропусков - телефонные книги

0.3. Вопрос 1: Связано ли общее количество записей компании в телефонных книгах с долей плохих оценок? Проявляется ли связь сильнее у руководителей?

Для построения графиков разделим компании на 4 группы: малые, средние, крупные и очень крупные, для каждой группы будем считать процент компаний у которых есть хотябы одна негативная запись.


```
df_q1 <- df %>%
  filter(!is.na(phb_bad_perc_dir)) %>%
  mutate(
    company_size = case_when(
      phb_all <= 100 ~ "1. Малый",
      phb_all <= 1000 ~ "2. Средний",
      phb_all <= 5000 ~ "3. Крупный",
      TRUE ~ "4. Очень крупный"
    )
  )

ggplot(df_q1, aes(x = company_size, y = phb_bad_perc_dir, fill = company_size)) +
  geom_boxplot(outlier.alpha = 0.1, alpha = 0.7) +
  coord_cartesian(ylim = c(0, 5)) +
  scale_fill_brewer(palette = "Blues") +
  labs(
    title = "Доля негатива в контактах руководства по размерам компаний",
    x = "Категория размера компаний",
    y = "Доля негативных записей",
    fill = "Размер"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```



```
df_q1_share <- df_q1 %>%
  group_by(company_size) %>%
  summarise(
    total_companies = n(),
    bad_companies = sum(phb_all_bad_dir > 0, na.rm = TRUE),
    share_bad_percent = round((bad_companies / total_companies) * 100, 2)
  )

ggplot(df_q1_share, aes(x = company_size, y = share_bad_percent, fill = company_size)) +
  geom_col(alpha = 0.85, width = 0.6) +
  geom_text(aes(label = paste0(share_bad_percent, "%")), vjust = -0.5, fontface = "bold") +
  scale_fill_brewer(palette = "Oranges") +
  labs(
    title = "Процент компаний с негативными отметками",
    x = "Категория",
    y = "Доля компаний"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```



Вывод: основные выводы, которые можно сделать это то, что у крупных компаний негатив находится чаще (почти у каждой 4 компании есть хотя бы одна метка у руководства), в то время как у малого бизнеса это реже. Мне кажется, что можно сделать вывод, что если у крупной компании есть негативный отзыв это не показатель мошенничества, однако если у маленькой компании больше процент негативных отзывов, это сигнал риска.


0.4. Вопрос 2: Связана ли высокая доля претензий по кредитам с общей долей негатив в ТК?

Разобьем как и в прошлой гипотезе на четыре группы: по количеству претензий по кредитам - нет претензий, низкий риск, средний риск и высокий риск и вычисляем в каждой категории долю компаний где есть хотя бы одна негативная запись.

```
df_q2 <- df %>%
  filter(!is.na(claims_percent), !is.na(phb_bad_perc)) %>%
  mutate(
    claim_group = case_when(
      claims_percent == 0 ~ "Нет претензий",
      claims_percent <= 10 ~ "Низкий риск ",
      claims_percent <= 30 ~ "Средний риск",
      TRUE ~ "Высокий риск"
    )
  ) %>%
  group_by(claim_group) %>%
  summarise(
    total_companies = n(),
    mean_bad_perc = round(mean(phb_bad_perc, na.rm = TRUE), 3),
    share_has_bad = round(sum(phb_all_bad > 0, na.rm = TRUE) / n() * 100, 2)
  )

ggplot(df_q2, aes(x = claim_group, y = share_has_bad, fill = claim_group)) +
  geom_col(alpha = 0.85, width = 0.6) +
  geom_text(aes(label = paste0(share_has_bad, "%")), vjust = -0.5, fontface = "bold") +
  scale_fill_brewer(palette = "YlOrRd") +
  labs(
    title = "Связь претензий по кредитам и наличия негатива в телефонных книгах",
  )
```

```
x = "Категория доли претензий по кредитам",
y = "Процент компаний с негативом в ТК"
) +
theme_minimal() +
theme(legend.position = "none")
```



Вывод: прямой связи между этими признаками не наблюдается, они содержат разную информацию и их можно использовать как независимые признаки


0.5. Вопрос 3: Правда ли что компании с юльшим количеством отзывов на платформах обладают меньшей долей негатива в телефонных книгах?

Складываем отзывы со всех платформ, получаем общий уровень у каждой компании, группируем и высчитываем риск по негативным отметкам.

```
df_q3 <- df %>%
  mutate(
    total_reviews = coalesce(reviews_cnt_ya, 0) +
      coalesce(reviews_cnt_2gis, 0) +
      coalesce(reviews_cnt_avito, 0) +
      coalesce(reviews_cnt_yell, 0),

    activity_group = case_when(
      total_reviews == 0 ~ "Нет отзывов",
      total_reviews <= 10 ~ "Низкая",
      total_reviews <= 100 ~ "Средняя",
      TRUE ~ "Высокая"
    )
  ) %>%
  group_by(activity_group) %>%
  summarise(
    total_companies = n(),
    mean_phb_bad = round(mean(phb_bad_perc, na.rm = TRUE), 3),
    share_bad_companies = round(sum(phb_all_bad > 0, na.rm = TRUE) / n() * 100, 2)
  )
```

```
ggplot(df_q3, aes(x = activity_group, y = share_bad_companies, fill = activity_group)) +
  geom_col(alpha = 0.85, width = 0.6) +
  geom_text(aes(label = paste0(share_bad_companies, "%")), vjust = -0.5, fontface = "bold") +
  scale_fill_brewer(palette = "Blues") +
  labs(
    title = "Процент компаний с негативом в ТК в зависимости от публичной активности",
    x = "Категория публичной активности",
    y = "Процент компаний с негативом в ТК"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```



Вывод: на графике четко видно прямую зависимость: чем выше активность у компании, тем чаще встречается негатив, поэтому можно сделать вывод, что наличие негативных записей у публчного бизнеса с большим количеством отзывов это нормально, однако если компания принадлежит первой группе и имеет высокий процент негатив это зона риска.

Для выявления сиильных взаимосвязей построим корреляционную матрицу.

```
library(corrplot)

corr_data <- df %>%
  select(
    log_phb_all, log_phb_all_bad, phb_bad_perc,
    phb_bad_perc_dir, claims_percent, claims_num,
    appl_num, ratings_cnt_ya, reviews_cnt_2gis
  ) %>%
  mutate(across(everything(), ~ ifelse(is.na(.), 0, .)))


cor_matrix <- cor(corr_data, method = "spearman")

corrplot(cor_matrix,
  method = "color",
  type = "upper",
```

```

tl.col = "black",
tl.srt = 45,
addCoef.col = "black",
number.cex = 0.75,
diag = FALSE,
title = "Матрица корреляций",
mar = c(0, 0, 2, 0)

```



Вывод: построив график корреляции можно сделать следующие выводы: существует прямая связь между претензиями по кредитам и их количеством; негативная информация в ТК почти полностью дублирует негатив в целом; негативные отзывы на руководителей почти не коррелируют с показателями компаний.

0.6. Вопрос 4: Как изменяется количество негативных отзывов в зависимости от активности?

Поскольку в моих данных нет информации про дату и время, будем анализировать количество активных отзывов относительно пользовательской активности. Разделим предприятия на 4 типа финансовой активности и для каждой рассчитаем долю организаций, имеющих негативный опыт в ТК

```

df_time <- df %>%
  filter(!is.na(appl_num)) %>%
  mutate(
    activity_stage = case_when(
      appl_num == 1 ~ "1 заявка",


```

```

    appl_num <= 3 ~ "2-3",
    appl_num <= 10 ~ "4-10",
    TRUE ~ ">10"
  ),
  activity_stage = factor(activity_stage, levels = c(
    "1 заявка",
    "2-3",
    "4-10",
    ">10"
  ))
) %>%
group_by(activity_stage) %>%
summarise(
  total_companies = n(),
  share_has_bad = round(sum(phb_all_bad > 0, na.rm = TRUE) / n() * 100, 2)
)

ggplot(df_time, aes(x = activity_stage, y = share_has_bad, fill = activity_stage)) +
  geom_col(alpha = 0.85, width = 0.6) +
  geom_text(aes(label = paste0(share_has_bad, "%")), vjust = -0.5, fontface = "bold") +
  scale_fill_brewer(palette = "Blues") +
  labs(
    title = "Динамика накопительного риска по этапам финансовой активности",
    x = "Этап кредитной активности",
    y = "Процент компаний с негативом в ТК"
  ) +
  theme_minimal() +
  theme(legend.position = "none")

```



Вывод: На первых этапах работы компании доля негатива находится на стабильном уровне, у компаний с активным поиском кредитов доля с негативом резко возрастает, частая подача заявок на кредиты, сигнализирует о трудностях, что напрямую отражается на росте негативных отметок.

0.7. Вопрос 5: Попытка предсказать негативный рейтинг

Для выполнения этой части работы воспользуемся методом Scoring Rule-Based: на основе полученных закономерностей зададим систему штрафных баллов для распределения компаний по группам. Возьмем 4 основных проанализированных показателя: негатив по компании, негатив по руководству, претензии по кредитам и аномальную кредитную активность для каждой категории выделим штрафные баллы по которым будем оценивать риск той или иной компании. Тогда каждая компания получает число от 0 до 100 и в зависимости от этого числа будет попадать в одну из трех групп риска: низкую, среднюю и высокую.

```
df_scored <- df %>%
  mutate(
    phb_bad_p = ifelse(is.na(phb_bad_perc), 0, phb_bad_perc),
    phb_dir_p = ifelse(is.na(phb_bad_perc_dir), 0, phb_bad_perc_dir),
    claims_p = ifelse(is.na(claims_percent), 0, claims_percent),
    appl_n = ifelse(is.na(appl_num), 0, appl_num),


    score_phb = case_when(
      phb_bad_p > 0.05 ~ 35,
      phb_bad_p > 0 ~ 15,
      TRUE ~ 0
    ),
    score_dir = case_when(
      phb_dir_p > 0.05 ~ 25,
      phb_dir_p > 0 ~ 10,
      TRUE ~ 0
    ),
    score_claims = case_when(
      claims_p > 30 ~ 25,
      claims_p > 0 ~ 10,
      TRUE ~ 0
    ),
    score_appl = case_when(
      appl_n > 10 ~ 15,
      appl_n > 5 ~ 5,
      TRUE ~ 0
    ),

    risk_index = score_phb + score_dir + score_claims + score_appl,

    risk_category = case_when(
      risk_index == 0 ~ "Низкий",
      risk_index <= 30 ~ "Умеренный",
      TRUE ~ "Высокий"
    )
  )

ggplot(df_scored, aes(x = risk_category, fill = risk_category)) +
  geom_bar(alpha = 0.85, width = 0.5) +
  geom_text(stat = "count", aes(label = ..count..), vjust = -0.5, fontface = "bold") +
  scale_fill_manual(values = c("#2b8cbe", "#e6550d", "#de2d26")) +
  labs(
    title = "Распределение компаний по Индексу",
    x = "Категория",
    y = "Количество",
    fill = "Зона"
```

```
) +
theme_minimal() +
theme(legend.position = "none")
```



Вывод: подавляющее большинство компаний попали в зону с низким уровнем риска, однако 2352 компании все таки представляют угрозу.